Beacon Biosignals Sleep Staging Challenge 2025

DEGENEVE Hugo, KAPOTOS Fotios

9 janvier 2026

1 Introduction

Ce rapport présente le pipeline de traitement et le modèle développés dans le cadre du *Beacon Biosignals Sleep Staging Challenge 2025*, visant à prédire automatiquement les stades du sommeil à partir de signaux physiologiques. L'approche proposée a permis d'obtenir un score de **0.78046** sur le *public leaderboard* du challenge.

Les sections suivantes décrivent les étapes de prétraitement, le modèle utilisé, le protocole de validation croisée et l'analyse des résultats obtenus.

2 Caractéristiques extraites

Cette section décrit l'ensemble des caractéristiques extraites à partir des signaux EEG après segmentation en époques. Chaque caractéristique est calculée par époque (30 secondes) et vise à capturer un aspect complémentaire de la dynamique neurophysiologique du sommeil, en particulier pour la discrimination des stades légers tels que N1.

2.1 Statistiques de base du signal

Pour chaque époque, des statistiques simples sont calculées à partir du signal EEG. La moyenne, l'écart-type et l'amplitude crête-à-crête (peak-to-peak) fournissent une mesure globale de l'amplitude et de la variabilité du signal. Ces descripteurs sont utiles pour distinguer les stades d'éveil, caractérisés par une activité plus variable, des stades de sommeil plus stables.

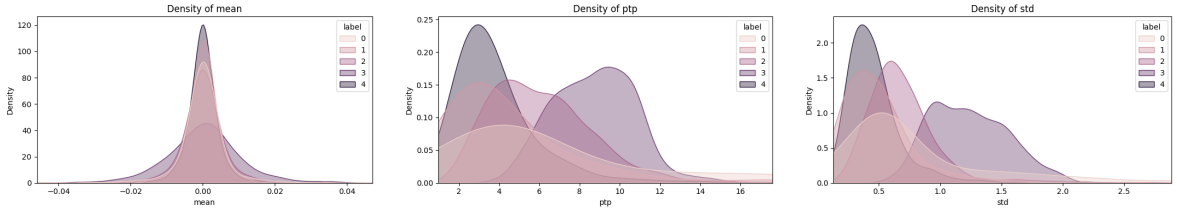


FIGURE 1 – Densité des features par classe.

2.2 Puissance spectrale par bande de fréquence

La densité spectrale de puissance (PSD) est estimée par la méthode de Welch, puis intégrée sur des bandes de fréquence physiologiquement pertinentes :

$$P_b = \int_{f_l}^{f_h} \mathrm{PSD}(f)\, df$$

Les puissances sont ensuite utilisées sous forme logarithmique afin de réduire la dynamique et améliorer la séparabilité :

$$\log P_b = \log(P_b + \varepsilon)$$

Ces caractéristiques sont centrales en analyse du sommeil, chaque stade étant associé à une signature fréquentielle distincte. Par exemple, l'augmentation relative de la puissance theta est un marqueur important du stade N1.

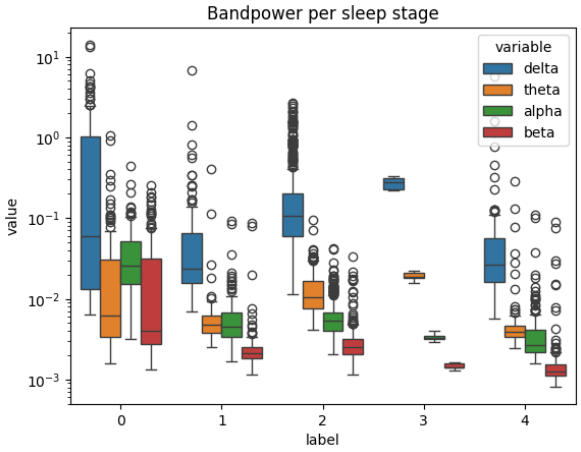


FIGURE 2 – Densité de la puissance spectrale par bande et par stade de sommeil.

La bande alpha permet de différencier les stades N1 et N2, tandis que la bande slow delta différencie les stades N2 et N3. Afin de rendre les caractéristiques moins sensibles à l'énergie globale du signal, des puissances relatives sont également calculées :

$$\tilde{P}_b = \frac{P_b}{\sum_k P_k}$$

Plusieurs indices combinant différentes bandes ont été introduits pour capturer explicitement des contrastes fréquentiels :

$$\begin{aligned}
\text{log_delta_theta} &= \log P_\delta - \log P_\theta, \\
\text{log_alpha_beta} &= \log P_\alpha - \log P_\beta, \\
\text{theta_dominance} &= \log P_\theta - \log\left(e^{\log P_\alpha} + e^{\log P_\beta}\right).
\end{aligned}$$

Ces rapports sont motivés par la physiologie du sommeil : le stade N1 se caractérise par une augmentation de l'activité theta et une diminution des composantes alpha et beta.

2.3 Paramètres de Hjorth

Les paramètres de Hjorth résument le signal dans le domaine temporel et fréquentiel :

$$\text{activité} = \text{var}(x), \quad \text{mobilité} = \sqrt{\frac{\text{var}(\dot{x})}{\text{var}(x)}}, \quad \text{complexité} = \frac{\sqrt{\text{var}(\ddot{x})/\text{var}(\dot{x})}}{\text{mobilité}}$$

Ils fournissent une description compacte de l'amplitude, du contenu fréquentiel et de la régularité du signal, et sont largement utilisés en EEG pour la classification des états cérébraux.

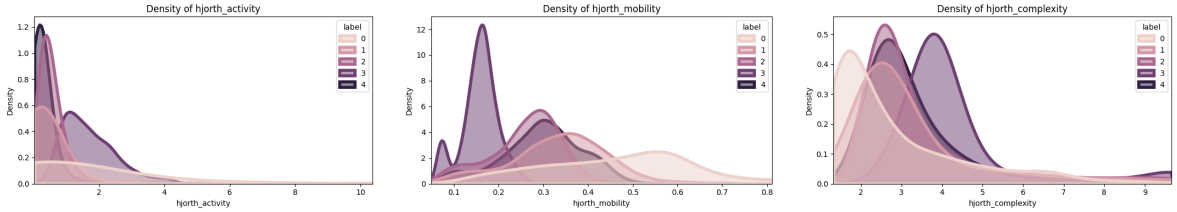


FIGURE 3 – Densité des paramètres de Hjorth par classe.

Ces caractéristiques permettent de séparer efficacement les stades N1 et N3. Le stade N3 étant l'un des plus difficiles à prédire correctement, ces features sont particulièrement importantes.

2.4 Entropie spectrale

L'entropie spectrale est calculée à partir de la PSD normalisée :

$$H = -\sum_f p(f) \log p(f), \quad p(f) = \frac{\text{PSD}(f)}{\sum_{f'} \text{PSD}(f')}$$

Elle mesure la complexité et la dispersion fréquentielle du signal. Une entropie élevée est généralement associée à des états plus désorganisés ou transitionnels, comme le sommeil N1.

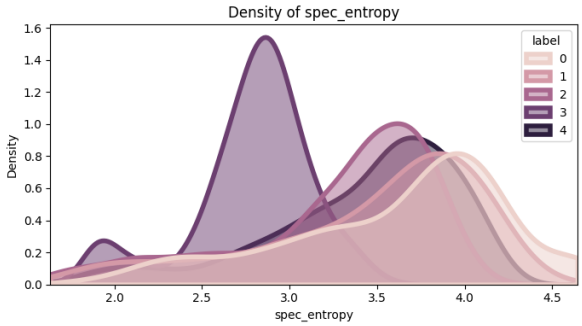


FIGURE 4 – Densité de l'entropie spectrale par classe.

Cette caractéristique permet notamment de différencier le stade N3.

2.5 Caractéristiques de forme spectrale

Des descripteurs globaux de la forme du spectre ont été extraits :

$$\mathrm{SEF}_{50},\ \mathrm{SEF}_{95} \quad \text{tels que} \quad \int_0^{\mathrm{SEF}_p} \mathrm{PSD}(f)\, df = p$$

ainsi que la platitude spectrale (spectral flatness), qui compare la moyenne géométrique à la moyenne arithmétique du spectre. Ces mesures indiquent si l'énergie est concentrée sur des fréquences spécifiques ou répartie uniformément, ce qui aide à différencier des stades structurés (N2, N3) de stades plus diffus (N1).



FIGURE 5 – Densité des caractéristiques SEF50 et SEF95 par classe.

Les classes 0 et 1 présentent une distribution très asymétrique sur ces variables, ce qui facilite leur séparation. Cela est particulièrement intéressant pour la classe 1, difficile à classifier.

2.6 Caractéristiques temporelles

Plusieurs caractéristiques temporelles sont extraites afin de capturer la dynamique du signal dans le domaine temporel. Le *Zero-Crossing Rate* (ZCR) mesure la fréquence des changements de signe du signal et constitue un indicateur simple de contenu fréquentiel relatif. La *Line Length*,

$$\text{Line Length} = \sum_t |x(t+1) - x(t)|,$$

quantifie la rapidité des variations et est sensible aux transitions brusques. La valeur efficace (*RMS*) résume l'énergie instantanée, tandis que la kurtosis caractérise la forme de la distribution statistique, en particulier la présence de valeurs extrêmes.

Ces descripteurs complètent les caractéristiques fréquentielles en capturant des propriétés temporelles locales du signal (Figure 6).

2.7 Caractéristiques de bursts sigma

Le signal est filtré dans la bande sigma, puis son enveloppe est estimée par transformée de Hilbert :

$$e(t) = |\mathcal{H}\{x_\sigma(t)\}|$$

Des statistiques sur cette enveloppe ainsi que la fraction de temps dépassant un seuil adaptatif sont calculées. Ces caractéristiques quantifient l'activité des fuseaux du sommeil, essentielles pour différencier N1 et N2.

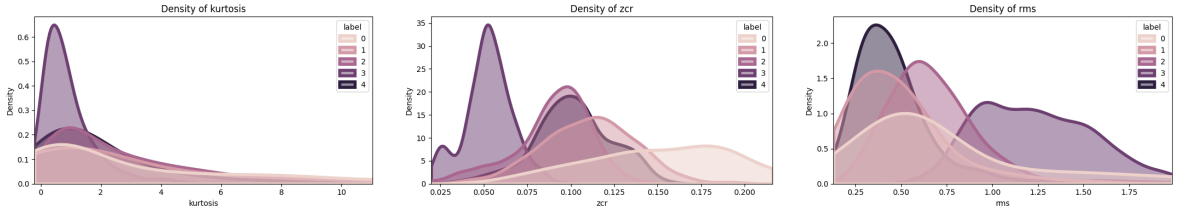


FIGURE 6 – Densité des caractéristiques temporelles par classe.

2.8 Dérive inter-époques

Enfin, une mesure de dérive temporelle est introduite via la distance cosinus entre vecteurs de caractéristiques consécutifs :

$$d_t = 1 - \frac{x_t \cdot x_{t-1}}{\|x_t\| \|x_{t-1}\|}$$

Cette dérive, moyennée sur une fenêtre temporelle, capture les transitions progressives entre stades et apporte une information dynamique complémentaire aux caractéristiques statiques par époque.

3 Description théorique du modèle

Cette section décrit le modèle final utilisé pour la classification des stades du sommeil. Le modèle repose sur une approche en deux niveaux : (i) une classification discriminante epoch par epoch à l'aide d'un modèle de type *gradient boosting* (XGBoost), puis (ii) une étape de décodage temporel visant à imposer une cohérence physiologique entre les prédictions successives. Cette combinaison permet de tirer parti à la fois de la richesse des variables extraites et de la forte structure temporelle propre au sommeil.

3.1 Cadre du problème

Le problème de *sleep staging* consiste à attribuer à chaque époque de 30 secondes un label discret parmi l'ensemble :

$$\mathcal{Y} = \{\text{Wake}, \text{N1}, \text{N2}, \text{N3}, \text{REM}\}.$$

Chaque époque est représentée par un vecteur de variables numériques extraites du signal EEG. Contrairement à une hypothèse d'indépendance entre observations, les stades du sommeil présentent une dynamique temporelle marquée : certaines transitions sont fréquentes (par exemple N2 $\rightarrow$ N3), tandis que d'autres sont physiologiquement rares (par exemple Wake $\rightarrow$ N3). Le modèle doit donc capturer à la fois des relations non linéaires complexes entre les variables et la dépendance temporelle entre époques successives.

3.2 Classification discriminante par XGBoost

Principe général. XGBoost est un algorithme d'ensemble basé sur l'agrégation séquentielle d'arbres de décision peu profonds. Chaque nouvel arbre est entraîné pour corriger les erreurs des arbres précédents en minimisant une fonction de perte différentiable, ici la log-vraisemblance multinomiale (`multi:softprob`).

Ce choix est particulièrement adapté à notre problème pour plusieurs raisons :

— les relations entre les variables spectrales, statistiques et non linéaires sont fortement non linéaires ;
— les distributions des variables diffèrent selon les stades mais présentent des recouvrements importants ;
— XGBoost est robuste aux variables redondantes et peu sensible à l'échelle des features ;
— le modèle fournit naturellement des probabilités de classe, essentielles pour l'étape de décodage temporel.

Gestion du déséquilibre des classes. Les stades du sommeil sont fortement déséquilibrés (par exemple, N2 est beaucoup plus fréquent que N1 ou Wake). Afin d'éviter que le modèle ne privilégie excessivement les classes majoritaires, une pondération des observations est appliquée lors de l'entraînement. Le poids associé à une classe c est défini par :

$$w_c = \left(\frac{N_{\max}}{N_c} \right)^{\gamma},$$

où N_c est le nombre d'échantillons de la classe c, $N_{\max}$ le nombre d'échantillons de la classe majoritaire, et γ un hyperparamètre contrôlant l'intensité de la correction. Cette pondération permet d'améliorer significativement les performances sur les stades rares, en particulier N1.

Sortie du modèle. Pour chaque époque t, le modèle fournit un vecteur de probabilités :

$$p_t(k) = \mathbb{P}(Y_t = k \mid X_t), \quad k \in \mathcal{Y},$$

qui constitue une estimation des probabilités d'émission des stades conditionnellement aux features observées.

3.3 Limites d'une prédiction indépendante

Une prédiction directe par maximisation de $p_t(k)$ (décodage *argmax*) traite chaque époque indépendamment. En pratique, cette approche conduit à des hypnogrammes bruités, avec des changements de stade trop fréquents et physiologiquement peu plausibles (par exemple des alternances rapides Wake–N2–Wake).

Une solution intermédiaire consiste à lisser temporellement les probabilités par une moyenne glissante. Bien que cette méthode améliore la stabilité locale, elle reste heuristique et ne permet pas d'intégrer explicitement les probabilités de transition entre stades.

Ces limites motivent l'introduction d'un modèle probabiliste séquentiel.

3.4 Décodage temporel par modèle de Markov caché

Modélisation HMM. Nous modélisons la séquence de stades du sommeil d'un patient par un modèle de Markov caché (HMM), dans lequel :
— les états cachés correspondent aux stades du sommeil ;
— les probabilités d'émission sont données par les sorties probabilistes de XGBoost ;
— les probabilités de transition entre états sont estimées empiriquement à partir des données d'apprentissage.

Les probabilités de transition $A_{ij} = \mathbb{P}(Y_{t+1} = j \mid Y_t = i)$ sont estimées par comptage des transitions observées dans les hypnogrammes d'entraînement, avec un lissage de Laplace contrôlé par le paramètre α afin d'éviter les probabilités nulles. De même, la distribution initiale des stades est estimée à partir des premiers états de chaque nuit.

Décodage par l'algorithme de Viterbi. Étant donnée une séquence d'observations $(X_1, \ldots, X_T)$, le décodage consiste à trouver la séquence de stades la plus probable :

$$\hat{Y}_{1:T} = \arg\max_{Y_{1:T}} \left[\log \pi_{Y_1} + \sum_{t=1}^{T} \log p_t(Y_t) + \sum_{t=2}^{T} \log A_{Y_{t-1}, Y_t} \right].$$

Cette optimisation est réalisée efficacement à l'aide de l'algorithme de Viterbi. Le résultat est un hypnogramme globalement cohérent, respectant les transitions physiologiques typiques du sommeil.

3.5 Pipeline de validation croisée

L'évaluation du modèle est réalisée à l'aide d'une validation croisée par groupes, afin d'éviter toute fuite d'information entre patients. Les données étant organisées par nuit, toutes les époques associées à un même patient sont systématiquement affectées au même pli. Nous utilisons pour cela une validation croisée `GroupKFold` à K plis.

Pour chaque pli, le pipeline suivant est appliqué :

1. entraînement du classifieur XGBoost sur les patients du jeu d'apprentissage, en tenant compte du déséquilibre des classes ;
2. estimation des paramètres du décodage temporel (distribution initiale et matrice de transition du HMM) uniquement à partir des données d'apprentissage ;
3. prédiction des probabilités de classe pour les patients du jeu de validation ;
4. décodage temporel des prédictions afin d'obtenir une séquence de stades cohérente à l'échelle de la nuit.

Les performances sont évaluées à l'aide du score F1 macro sur chaque pli, puis agrégées en moyenne et écart-type. Ce protocole permet d'estimer de manière robuste la capacité de généralisation du pipeline complet sur des patients non vus.

3.6 Sélection de modèle et prédiction finale

Le protocole expérimental est structuré en deux phases complémentaires. Dans un premier temps, la validation croisée par groupes est utilisée comme outil d'évaluation et de comparaison afin de tester différentes configurations du modèle. Cette étape permet d'analyser l'impact des choix de modélisation (hyperparamètres de XGBoost, pondération des classes, stratégie de décodage temporel) sur les performances de généralisation.

Dans un second temps, les hyperparamètres sont sélectionnés par recherche sur grille en optimisant le score F1 macro moyen obtenu en validation croisée. Une fois la configuration finale fixée, le modèle est entraîné sur l'ensemble des données d'apprentissage disponibles. Les paramètres du modèle temporel sont alors estimés sur toutes les séquences d'entraînement, puis utilisés pour produire les prédictions finales sur le jeu de test.

4 Résultats

4.1 Performances en validation croisée

Les performances du modèle ont été évaluées par validation croisée par groupes, chaque pli correspondant à un ensemble distinct de patients.

La métrique principale retenue est le score F1 macro, choisi afin de pondérer équitablement les différents stades du sommeil malgré leur fort déséquilibre. Les scores F1 macro obtenus pour chacun des $K = 5$ plis sont reportés dans le Tableau 1. Le modèle atteint un score moyen de

$$\mathrm{F1}_{\mathrm{macro}} = 0.72 \pm 0.06,$$

ce qui indique des performances globalement stables, avec une variabilité modérée entre plis. Cette variabilité reflète principalement les différences inter-patients, certaines nuits présentant des distributions de stades ou des dynamiques temporelles plus difficiles à modéliser.

TABLE 1 – Scores F1 macro obtenus en validation croisée par groupes (5 plis).

Pli	**F1 macro**
Pli 1	0.75
Pli 2	0.66
Pli 3	0.76
Pli 4	0.81
Pli 5	0.64
Moyenne ± écart-type	**0.72 ± 0.06**

Au-delà de la performance globale, l'analyse des métriques par classe, agrégées sur l'ensemble des plis (Tableau 2), met en évidence des comportements contrastés selon les stades. Les stades Wake, N2 et N3 présentent des scores de précision et de rappel élevés et relativement stables. En revanche, le stade N1 affiche des performances plus faibles et une variabilité plus importante entre plis. Ce résultat est cohérent avec la nature transitoire du stade N1, sa faible représentation dans les données et sa proximité physiologique avec les stades voisins (Wake et N2), ce qui en fait le stade le plus ambigu à détecter.

TABLE 2 – Performances par stade en validation croisée : moyenne ± écart-type sur les 5 plis.

Stade	**Précision**	**Recall**	**F1**
Wake	0.88 ± 0.10	0.83 ± 0.15	0.84 ± 0.11
N1	0.43 ± 0.17	0.42 ± 0.17	0.39 ± 0.10
N2	0.85 ± 0.13	0.85 ± 0.10	0.84 ± 0.06
N3	0.86 ± 0.17	0.86 ± 0.20	0.83 ± 0.11
REM	0.76 ± 0.11	0.72 ± 0.19	0.72 ± 0.11

4.2 Analyse de la matrice de confusion

La Figure 7 montre la matrice de confusion agrégée sur l'ensemble des plis de validation croisée, normalisée par ligne. Le modèle reconnaît efficacement les stades Wake, N2 et N3, avec des taux de classification correcte supérieurs à 80 %.

Les principales erreurs concernent des confusions entre stades physiologiquement adjacents. Le stade N3 est presque exclusivement confondu avec N2, tandis que le stade REM est parfois confondu avec N2 ou N1. Le stade N1 reste le plus difficile à détecter, avec de nombreuses confusions vers Wake, N2 et REM, ce qui reflète son caractère transitoire et faiblement marqué.

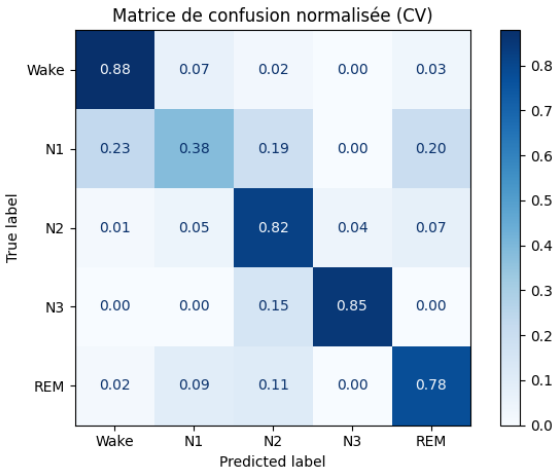


FIGURE 7 – Matrice de confusion agrégée sur les plis de validation croisée, normalisée par ligne. Chaque ligne représente la distribution des prédictions conditionnellement au stade réel.

Les confusions entre stades éloignés (par exemple Wake et N3) sont très rares, indiquant que le modèle capture correctement la structure globale de l'architecture du sommeil.

4.3 Reconstruction des hypnogrammes

La Figure 8 illustre des exemples d'hypnogrammes reconstruits à partir de prédictions hors-échantillon, avec un patient représentatif par pli de validation croisée. Dans la majorité des cas, le modèle reproduit correctement la structure temporelle globale du sommeil, incluant l'alternance des cycles et la durée relative des différents stades.

On observe néanmoins une variabilité entre plis. En particulier, le pli 4 présente une dégradation plus marquée de la qualité de reconstruction, avec des erreurs plus fréquentes et des transitions moins bien localisées. Ce comportement est cohérent avec les performances quantitatives plus faibles observées pour ce pli, et illustre l'impact de la variabilité inter-patients sur la tâche de classification des stades du sommeil.

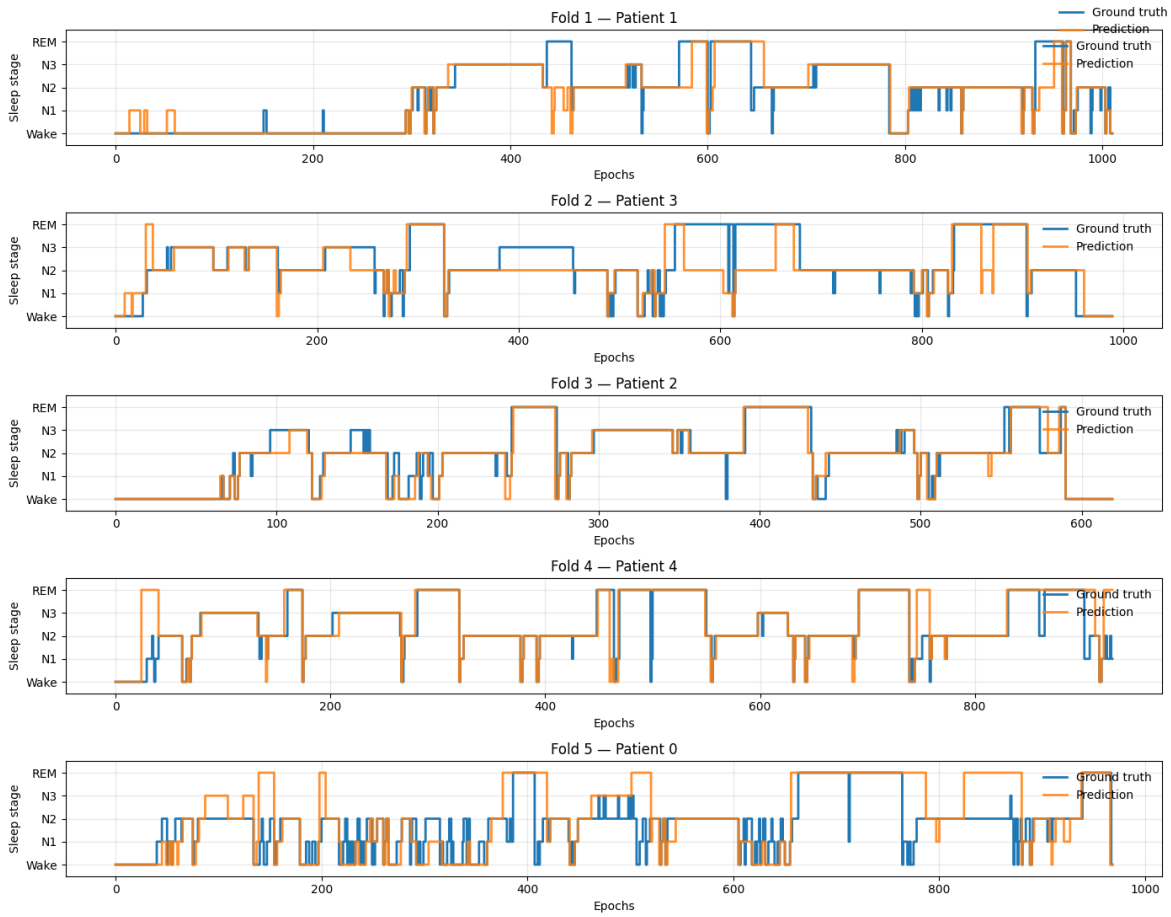


FIGURE 8 – Exemples d'hypnogrammes reconstruits à partir de prédictions hors-échantillon issues de la validation croisée. Un patient représentatif est présenté pour chaque pli. Les annotations expertes (Ground truth) sont comparées aux prédictions du modèle (Prediction).